동국대학교
dongguk university

응용수치해석 및 실습 제12주

권기운

- 지도 학습 vs. 비지도 학습

- 비지도 기계 학습
  - 군집화(Clustering)
  - 주요소분석(PCA:Principal Component Analysis)
  - 고유얼굴(eigenface)

지도 학습 vs. 비지도 학습

- Supervised learning vs. unsupervised learning
- 지도 학습 : 정답 레이블과 입력 데이터 셋이 주어지며, 입력과 출력과의 관계를 함수로서 학습하여야 한다. 필기 숫자 분류 문제(MNIST)는 대표적인 지도학습 문제이다.
- 비지도 학습 : 결과물이 어떻게 생겼는지 거의 알지 못한다. 변수들의 효과를 반드시 알 필요 없는 데이터로부터 구조를 도출한다. 대표적으로 클러스터링은 어떤 화소가 어떤 영역에 속해 있는지에 대한 사전 지식 없이 분류하는 영상처리 기술이라 볼 수 있다.
- 영상 분할 vs. 영상 분류
- 어떤 컴퓨터 프로그램이 성능 척도 P에 의해 측정된 작업 T에서의 성능이 경험 E로 향상
  : 작업 T와 성능 척도 P와 관련하여 경험 E를 통해 학습한다.
- 필기 숫자 분류 문제 (MNIST)
  - 작업 T : 영상에 레이블(숫자) 할당
  - 성능 P : 정확히 식별된 영상들의 비율
  - 경험 E : Training
  - 학습 프로그램

비지도 기계학습 : k-means

- 영상에 색상 이산화(Vector Quantization)을 수행
  - 영상의 화질(공간해상도)를 유지하면서 256가지 고유 색상에서 4가지 고유 색상으로 색상 수를 줄이는 방법 수행
  - 색상은 3차원 공간에서 표현됨
  - k-means는 마지막 4개 색상 클러스터를 찾는 데 사용됨

- Codebook : 색상 팔레트(color palette) : k-means로 구한 클러스터의 중심
  - 1 byte : 256개 색상
  - RGB 인코딩 : 화소당 3 byte
  - GIF 형식 : 이 팔레트 사용

- K-means를 사용하여 영상 분할 수행
  - 랜덤 코드북 vs. 색 양자화 후

- 양자화 결과 비슷 : k-means
  - 50416 화소 중에서 1000개 화소 랜덤 추출 후 k-means 수행 후 양자화
  - 전체 50416 화소 양자화

Example 1. K-means : Quantization

K-means

Quantized image (64 colors, K-means)

Quantized image (32 colors, K-means)

Quantized image (16 colors, K-means)

Quantized image (8 colors, K-means)

Random

Quantized image (64 colors, K-means)

Quantized image (32 colors, K-means)

Quantized image (16 colors, K-means)

Quantized image (8 colors, K-means)

Original image (256 colors)

영상분할을 위한 스펙트럼 클러스터링

- 스펙트럼 클러스터링은 그래프 컷 graph cuts 문제를 해결한다.
- 영상을 연결된 화소의 그래프로 볼 수 있음
- 영역을 정의하는 그래프 컷을 선택하고, 컷의 기울기와 영역의 볼륨의 비율을 최소화
- Scikit-learn의 SpectralClustering() 함수 사용하여 영상 분할
- K-means를 사용한 이진 분할과 비교
- 스펙트럼 클러스터링은 k-means 클러스터링보다 영상 분할에 유리

Example 2. 2-means vs. Spectral

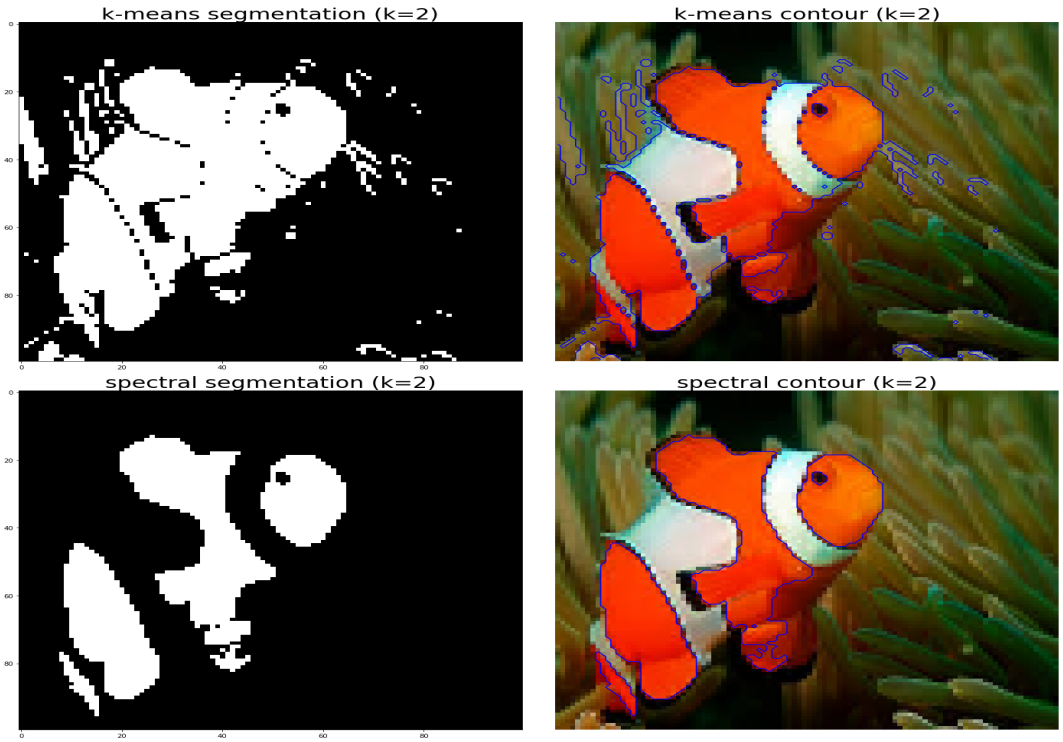

Lenna

k-means segmentation (k=2)
k-means contour (k=2)
spectral segmentation (k=2)
spectral contour (k=2)
0
20
40
60
80

비지도 기계학습 : PCA

- 주성분 분석 : Principal Component Analysis
- 직교 변환을 사용하는 통계/비지도 기계학습법
- 상관 관계가 있는 변수의 관측 집합을 주성분이라 하는 선형 상관관계가 없는 변수 집합으로 변환
- 데이터셋의 최대 분산 방향을 주성분이라 한다.
- 선형 차원 감소
- 대부분, 데이터셋의 거의 모든 분산을 포함하는 지배적인 주성분은 적음
- 여러 차원을 갖는 데이터셋의 2차원 시각화에 사용
- 응용: 고유 얼굴 eigenface : 임의의 얼굴을 나타낼수 있는 기본요소를 찾는 것
- Scikit-learn의 숫자 데이터셋 사용 : mini MNIST
  - 필기 숫자 1797개, 8*8화소
  - 데이터 행렬의 행: 영상
  - 64차원 데이터 셋
- 2차원 투영과 시각화
  - PCA()함수를 이용하여 두 개의 지배적인 주성분을 찾고, 이를 따라 데이터 셋 투영
  - 데이터 좌표와 고유한 색상으로 표시된 숫자 레이블을 그림
  - 숫자들이 일부 겹치지만, 어느 정도 분리되어 있음
  - 같은 숫자 값들은 공간적으로도 모여 있음

Example 3. MiniMNIST(1797,8*8)

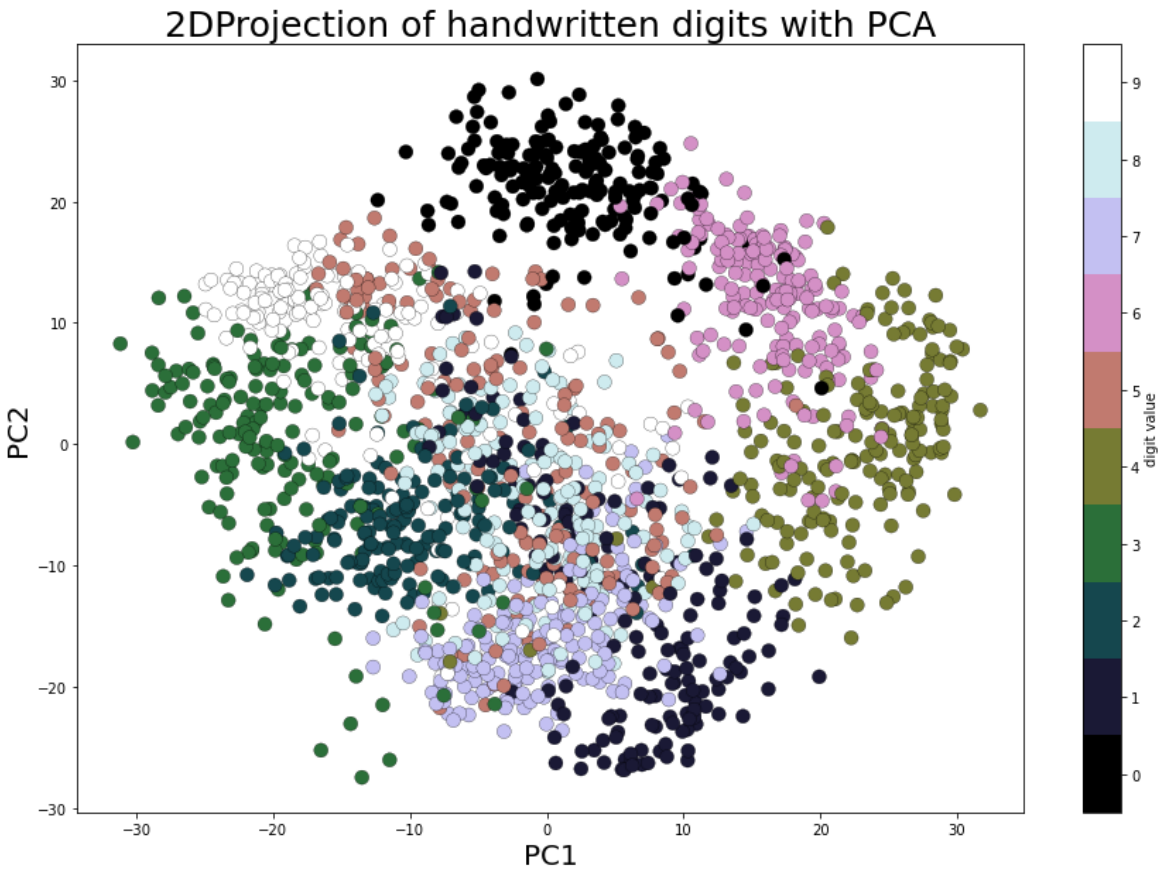

동국대학교
dongguk university

고유얼굴

- Scikit-learn의 Olivetti 얼굴 데이터셋
  - 64*64화소 얼굴 400개
- Z-스코어 정규화 수행: 데이터셋 전처리
  - 모든 얼굴에 평균 얼굴을 빼고, 표준 편차 얼굴로 나눔
  - 얼굴 영상에 PCA 적용 전 필요한 단계
- PCA()로 주성분 계산, 4096개 중에서 64개 선택
- 주성분 개수가 늘어날 때, 영상 데이터셋의 분산 비율이 어떻게 되는 지 시각화
- 분산의 90%는 64개 주성분으로 설명가능 (SD vs. # of components 그래프 참조)

Example 4. 25 랜덤 얼굴 영상

Mean face, SD face, SD vs. # of PCs

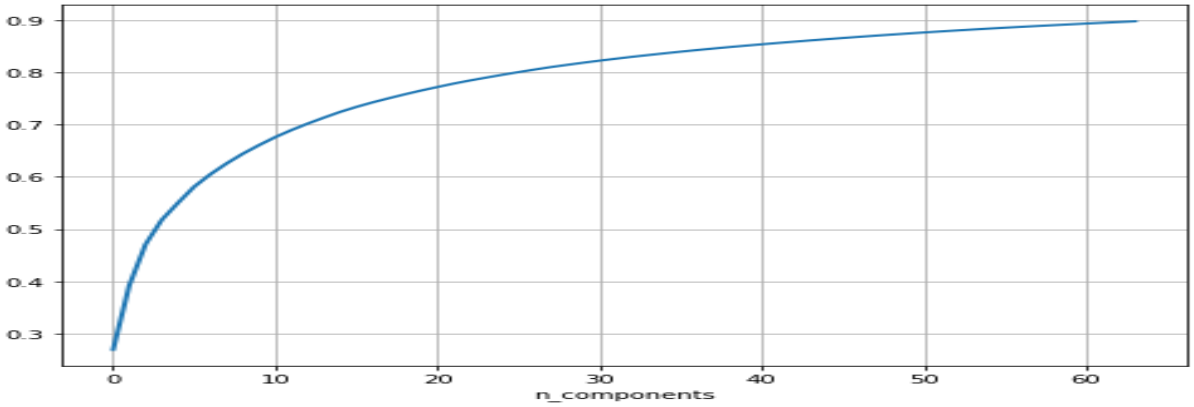

Mean face

SD face

동국대학교
dongguk university

고유 얼굴과 재구성

- 계산된 주성분 PC는 서로 직교하고 각 4096화소를 포함하며 64*64영상으로 재구성할 수 있다.
- 고유얼굴을 계산하고 그 중 10개를 표시하였다.
- 얼굴을 64개의 지배적인 고유얼굴의 선형 결합으로 표현할 수 있다.
- Scikit-learn의 inverse-transform() 함수는 원본 공간으로 되돌리기 위해 사용
- 64개의 지배적인 고유얼굴만 사용하며, 나머지 고유 얼굴을 제외된다.
- 눈에 띄는 오류없이 원본 얼굴과 거의 비슷하게 보인다.
- 약간의 왜곡은 있어서 안경 안 쓴 사람이 안경을 쓰게 나오는 경우도 있다.
  - 하지만, 얼굴은 원본과 비슷하다.
- 각 고유 얼굴은 다른 얼굴 영상에 대해 다른 가중치를 갖는다.

Example 5. Eigenspace

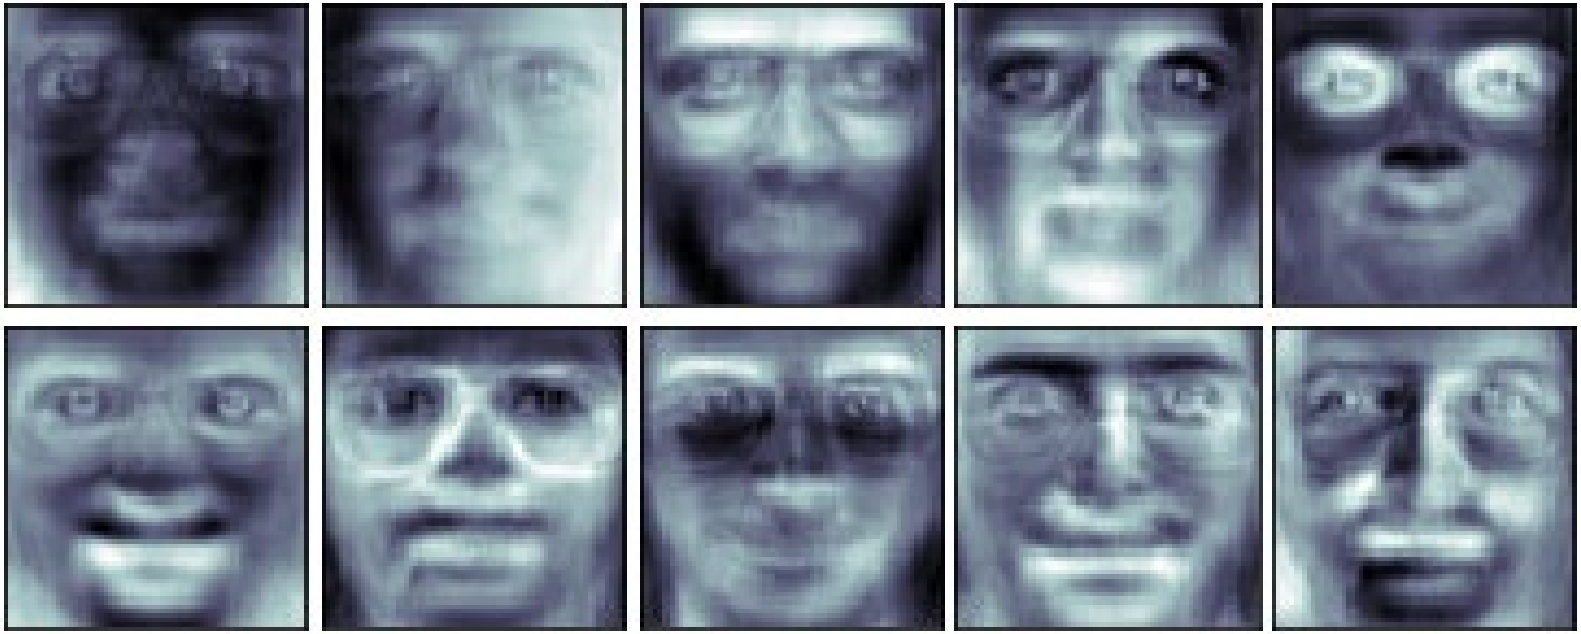

Example 6. Reconstruction

Example 7. Reconstruction 2 : Glasses

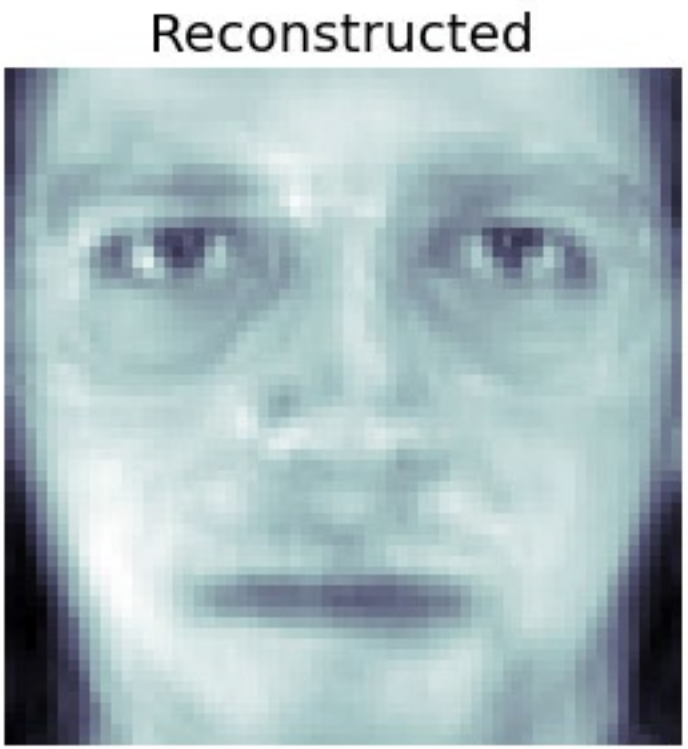

Conclusions

- 영상처리 문제를 해결하기 위한 몇가지 고전적인 기계학습 기술과 그 응용에 대해 논하였다.
- 클러스터링과 주성분 분석은 비지도 기계학습 알고리즘이다.
- scikit-learn을 사용하여 k-means와 스펙트럼 클러스터링 알고리즘을 시연하고, 벡터 양자화와 영상분할에 사용하는 방법을 보여주었다.
- 차원 감소에서 PCA 사용방법과 scikit-image의 필기 숫자 영상 데이터셋과 같은 고차원 데이터셋을 시각화하는 방법을 제시하였다.
- scikit-learn의 데이터셋을 이용하여 PCA로 고유얼굴을 구현하는 방법을 설명했다.